

Халықаралық ақпараттық технологиялар университеті

ӘОЖ: 004.93:617.735

Қолжазба құқығында

ЕСМУХАМЕДОВ НҰРМАҒАНБЕТ СЕЙТҚАЛИҰЛЫ

**Fundus кескіндерін жақсарту және CNN жіктеуі арқылы
диабеттік ретинопатияны автоматтандырылған диагностикалау**

8D06104 – Есептеу техникасы және бағдарламалық жасақтама

Философия докторы (PhD) дәрежесін
алуға арналған диссертация

Ғылыми консультанты
физика-математика ғылымдарының
кандидаты,
қауымдастырылған профессор,
Халықаралық ақпараттық
технологиялар университеті
Сапакова С.З.

Шетелдік ғылыми консультанты
профессор, Universiti Putra Malaysia
Al-Haddad S.A.R.

Қазақстан Республикасы
Алматы, 2026

МАЗМҰНЫ

НОРМАТИВТІК СІЛТЕМЕЛЕР.....	—
БЕЛГІЛЕУЛЕР МЕН ҚЫСҚАРТУЛАР	—
АНЫҚТАМАЛАР.....	—
КІРІСПЕ.....	—
1 ДИАБЕТТІК РЕТИНОПАТИЯНЫ АВТОМАТТАНДЫРЫЛҒАН ДИАГНОСТИКАЛАУДЫҢ ПРОБЛЕМАЛЫҚ САЛАСЫН ТАЛДАУ ЖӘНЕ ҚАЗІРГІ ЖАЙ-КҮЙІ	1
1.1 Диабеттік ретинопатияның медициналық және эпидемиологиялық контексті	1
1.1.1 Патофизиология және клиникалық градациялау жүйелері	1
1.1.2 Ресурстары шектеулі денсаулық сақтау жағдайындағы скрининг талаптары.....	4
1.2 Fundus кескіндерін алу және сапа вариабельдігі	7
1.2.1 Клиникалық тәжірибедегі кескін сапасының төмендеу көздері	7
1.2.2 Кескін сапасының диагностикалық модель өнімділігіне әсері	9
1.2.3 Fundus бейнелеудегі құрылғыға тәуелді вариабельділік.....	12
1.3 Ретинальды кескіндерді жіктеудегі Deep Learning тәсілдері	15
1.3.1 Медициналық бейнелеуге арналған Convolutional Neural Network архитектуралары.....	15
1.3.2 Офтальмологиялық диагностикадағы Transfer Learning және өзін-өзі бақылаусыз алдын ала оқыту	18
1.3.3 Медициналық кескіндерді жіктеудегі Explainability әдістері.....	21
1.4 DR автоматтандырылған скрининг жүйелеріне сыни талдау	23
1.5 Зерттеу мәселесін тұжырымдау және зерттеу бағытын негіздеу.....	27
1-тарау бойынша қорытындылар	1
2 FUNDUS IMAGE ТАЛДАУЫ ҮШІН IMAGE PREPROCESSING ЖӘНЕ DEEP LEARNING ТЕОРИЯЛЫҚ НЕГІЗДЕРІ	31
2.1 Image Enhancement әдістерінің математикалық негіздері	31
2.1.1 Histogram Equalization және Adaptive Contrast Enhancement	31
2.1.2 Қос шектеулі шектік мәні бар CLAHE формализациясы.....	35
2.1.3 Spatial Filtering және Noise Reduction әдістері	39
2.2 Convolutional Neural Networks теориялық негіздері.....	41
2.2.1 Convolution, Pooling және Feature Extraction операциялары	41
2.2.2 Imbalanced медициналық деректер жиынтықтары үшін Loss Functions және оптимизация.....	43
2.2.3 Regularization әдістері: Dropout, Batch Normalization және Data Augmentation	46
2.3 Transfer Learning және өзін-өзі бақылаусыз репрезентация оқыту теориясы	48
2.3.1 Визуалды домендер арасындағы Feature Transferability.....	48
2.3.2 Frozen-Layer және Progressive Fine-Tuning стратегиялары	50

2.3.3 Ретинальды бейнелеуге арналған домендік өзін-өзі бақылаусыз алдын ала оқыту	52
2.4 Ретинальды терапиядағы Laser–Tissue Interaction математикалық модельдеу	54
2.4.1 Fundus тіндерінің жауабын сипаттайтын Coupled Thermal-Optical Model (диагностикалық кескін белгілерін интерпретациялауға ықпалын қоса).....	54
2.5 Медициналық бейнелеуге арналған Deep Learning-тегі Explainability.....	57
2.5.1 Class Activation Mapping (CAM) және Grad-CAM математикалық формуляциясы.....	57
2.5.2 Офтальмологиялық контексттегі Attention Maps интерпретациясы.....	60
2.5.3 Сандық Explainability метрикалары ретіндегі ALO және IoU	61
2.6 Preprocessing бағалауға арналған кескін сапасы метрикалары	63
2-тарау бойынша қорытындылар	31
3 ИНТЕГРАЦИЯЛАНҒАН PREPROCESSING-CNN PIPELINE ЖОБАЛАУ ӘДІСТЕМЕСІ.....	67
3.1 Біріздендірілген Preprocessing Pipeline формализациясы	67
3.1.1 Pipeline кезеңдерінің спецификациясы: 8 кезеңді жүйе	67
3.1.2 Қос шектеулі шектік мәні бар модификацияланған CLANE алгоритмі	84
3.1.3 Класс теңсіздігін азайтуға арналған Augmentation стратегиясы	86
3.1.4 Сыртқы кескіндерді қабылдау хаттамасы	88
3.2 DR жіктеуге арналған CNN архитектураларын жобалау.....	90
3.2.1 ResNet-50 және EfficientNet-B3 негізгі эксперименттік архитектуралар ретінде.....	90
3.2.2 Тарихи анықтамалық архитектуралар (тек анықтама үшін).....	92
3.3 Transfer Learning және алдын ала оқыту әдістемесі	94
3.3.1 Бес класты DR жіктеуге арналған архитектураны бейімдеу	94
3.3.2 CNN магистралын офтальмологияға бейімделген өзін-өзі бақылаусыз алдын ала оқыту (тармағы).....	95
3.3.3 Екі кезеңді Fine-Tuning хаттамасын жобалау.....	97
3.3.4 Реттік класс құрылымына арналған Weighted Loss Function формуляциясы.....	98
3.4 Бағалау негіздемесі және өнімділік метрикалары	100
3.4.1 Көп метрикалық бағалау негіздемесі	100
3.4.2 Cross-Validation және статистикалық сенімділік хаттамалары	104
3-тарау бойынша қорытындылар	67
4 ЭКСПЕРИМЕНТТІК ЗЕРТТЕУ — PREPROCESSING-ТІҢ CNN ДИАГНОСТИКАЛЫҚ ӨНІМДІЛІГІНЕ ӘСЕРІ.....	108
4.1 Деректер жиынтықтары және эксперименттік конфигурация	108
4.1.1 Деңгейлік деректер жиынтығы архитектурасы.....	108
4.1.2 Класс таралуын талдау және деректерді бөлу стратегиясы.....	114
4.1.3 Аппараттық спецификация және қайта жаңғырту хаттамасы	117

4.2 Эксперимент 1: Интеграцияланған Pipeline үстемдігі — EyePACS-та Pipeline + домендік алдын ала оқыту vs. Baseline (H-1)	—
4.2.1 Қалпына келтірілген 2×2 факторлық жобалау (A–D конфигурациялары)	—
4.2.2 Оқыту динамикасы және конвергенция талдауы	—
4.2.3 Диагностикалық метрикаларды сандық салыстыру	—
4.3 Эксперимент 2: Pipeline кезеңдерін абляциялау + CLANE/σ жинақтары (H-2)	—
4.3.1 абляция жобалауы (0–6 деңгейлер)	—
4.3.2 CLANE шектік сезімталдық талдауы (H-2 қосалқы талдауы)	—
4.3.3 Flat-Field σ жинағы және кескін сапасы метрикалары	—
4.4 Эксперимент 3: APTOS 2019-дағы Cross-Dataset Transferability (H-4)	—
4.4.1 APTOS 2019-ға Zero-Shot Transfer	—
4.4.2 Baseline және Pipeline салыстыруы	—
4.5 Эксперимент 4: IDRiD + Clinical-дегі Grad-CAM Explainability (H-5)	—
4.5.1 Grad-CAM генерациялау хаттамасы	—
4.5.2 IDRiD зақымдану масктарымен сандық ALO және IoU	—
4.5.3 Деректер жиынтықтары бойынша Attention консистенттілігі	—
4.6 Эксперимент 5: IDRiD + Messidor-2-дегі клиникалық деградацияға төзімділік (H-7)	—
4.7 Эксперимент 6: DDR + ODIR-5K + RFMiD-тегі Device Domain Shift (H-6). —	
4.8 Эксперимент 7: Аз деректермен оқыту (IDRiD → Clinical)	—
4-тарау бойынша қорытындылар	108
5 СЕНІМДІЛІКТІ ВАЛИДАЦИЯЛАУ ЖӘНЕ САЛЫСТЫРМАЛЫ ТАЛДАУ	—
5.1 Explainability нәтижелері	—
5.2 Статистикалық валидация	—
5.2.1 Bootstrap сенімділік интервалдары және Mixed-Effects моделі	—
5.2.2 Түпкілікті claim күштілік жіктеулері	—
5.3 Жарияланған жүйелермен салыстырмалы талдау	—
5.3.1 Жарияланған нәтижелермен Benchmarking: IDx-DR, EyeNuk, DeepMind	—
5.3.2 Performance-Complexity Trade-Off талдауы	—
5.4 Ұсынылған тәсілдің шектеулері мен шекаралық шарттары	—
5-тарау бойынша қорытындылар	—
6 РЕСУРСТАРЫ ШЕКТЕУЛІ ОРТАҒА АРНАЛҒАН DR АВТОМАТТАНДЫРЫЛҒАН СКРИНИНГ ЖҮЙЕСІНІҢ АРХИТЕКТУРАСЫ	119
6.1 Жүйелік талаптар және жобалау қағидалары	120
6.1.1 Функционалдық және функционалдық емес талаптар спецификациясы	119
6.1.2 PACS және ENR интеграциясы бар модульдік архитектура	122
6.2 AI өңдеу модулін жобалау	121
6.2.1 Конфигурацияланатын Pipeline параметрлері бар Preprocessing Engine	126

6.2.2 Model Selection Logic бар Inference модулі.....	128
6.3 Клиникалық жұмыс процесіне интеграция	123
6.3.1 Ауылдық жерлерде орналастыруға арналған телемедицина және портативті құрылғыларды қолдау.....	130
6.3.1.1 Таратылған телемедицина жүйелерінде орналастыру.....	130
6.3.1.2 Ұлттық eHealth платформаларымен интеграция.....	131
6.3.1.3 Ресурстары аз аймақтарда нақты уақыттағы қашықтан DR скринингі.....	132
6.3.2 Physician-in-the-Loop шешім қабылдауды қолдау интерфейсі	133
6.4 Деректер қауіпсіздігі және нормативтік сәйкестік негіздемесі.....	134
6.4.1 GDPR/HIPAA-ге сәйкес деректерді басқару хаттамалары.....	134
6.4.2 Қазақстан денсаулық сақтау инфрақұрылымына қолданылуы	136
6-тарау бойынша қорытындылар.....	119
ҚОРЫТЫНДЫ	—
ПАЙДАЛАНЫЛҒАН ӘДЕБИЕТТЕР ТІЗІМІ.....	146
ҚОСЫМШАЛАР.....	139
А қосымшасы — Preprocessing Pipeline бастапқы коды.....	—
Б қосымшасы — Қосымша эксперименттік нәтижелер және Confusion Matrices	—
В қосымшасы — Жүйе архитектурасының UML диаграммалары	—
Г қосымшасы — Енгізу сертификаттары және апробация актілері.....	—
Д қосымшасы — Grad-CAM визуализация галереясы	—
Е қосымшасы — Device Domain Shift қосымша кестелері	—

НОРМАТИВТІК СІЛТЕМЕЛЕР

Бұл диссертацияда келесі стандарттарға сілтемелер пайдаланылды:

Диссертация мен авторефератты ресімдеу жөніндегі нұсқаулық, Қазақстан Республикасы Білім және ғылым министрлігінің Жоғары аттестаттау комитеті, 2004 жылғы 28 қыркүйектегі № 377-3 ж.

ГОСТ 7.32-2001. Ғылыми-зерттеу жұмысы туралы есеп. Құрылымы және ресімдеу ережелері.

ГОСТ 7.1-2003. Библиографиялық жазба. Библиографиялық сипаттама. Жалпы талаптар мен жасау ережелері.

СТ ҚР 34.005-2002. Ақпараттық технология. Негізгі терминдер мен анықтамалар (бірінші басылым).

СТ ҚР 34.015-2002. Ақпараттық технология. Автоматтандырылған жүйелер стандарттарының жиынтығы. Ақпараттық жүйені құруға арналған техникалық тапсырма (бірінші басылым).

СТ ҚР 34.027-2006. Ақпараттық технологиялар. Бағдарламалық құралдарды жіктеу (бірінші басылым).

СТ ҚР 34.014-2002. Ақпараттық технология. Автоматтандырылған жүйелер стандарттарының жиынтығы. Автоматтандырылған жүйелер. Терминдер мен анықтамалар.

БЕЛГІЛЕУЛЕР МЕН ҚЫСҚАРТУЛАР

AI	Artificial Intelligence (жасанды интеллект)
ALO	Activation–Lesion Overlap (explainability метрикасы)
APTOS	Asia Pacific Tele-Ophthalmology Society (2019 Blindness Detection деректер жиынтығы)
AUC	Area Under the Curve (қисық астындағы аудан)
BYOL	Bootstrap Your Own Latent (өзін-өзі бақылаусыз оқыту әдісі)
CAM	Class Activation Mapping
CLAHE	Contrast-Limited Adaptive Histogram Equalization
CNN	Convolutional Neural Network
CNR	Contrast-to-Noise Ratio
DDR	Диабеттік ретинопатияны градациялау деректер жиынтығы (DDR)
DINO	self-Distillation with No labels (өзін-өзі бақылаусыз оқыту әдісі)
DR	Diabetic Retinopathy (диабеттік ретинопатия)
ECE	Expected Calibration Error
EHR	Electronic Health Record (электрондық денсаулық жазбасы)
EMD	Earth Mover's Distance
EyePACS	Eye Picture Archive Communication System (DR деректер жиынтығы)
FOV	Field of View (көру өрісі)
GDPR	General Data Protection Regulation
Grad-CAM	Gradient-weighted Class Activation Mapping
HIPAA	Health Insurance Portability and Accountability Act
IDRiD	Indian Diabetic Retinopathy Image Dataset
IoU	Intersection over Union
KL	Kullback–Leibler дивергенциясы
LAB	CIELAB түс кеңістігі
MLP	Multilayer Perceptron
MoCo	Momentum Contrast (өзін-өзі бақылаусыз оқыту әдісі)
NPV	Negative Predictive Value (теріс болжамдық мән)
OD	Optic Disc (көру дискісі)
ODIR-5K	Ocular Disease Intelligent Recognition деректер жиынтығы (5000 пациент)
PACS	Picture Archiving and Communication System
PPV	Positive Predictive Value (оң болжамдық мән)
ReLU	Rectified Linear Unit
RFMiD	Retinal Fundus Multi-disease Image Dataset
RIQA	Retinal Image Quality Assessment
ROC	Receiver Operating Characteristic
SimCLR	Simple framework for Contrastive Learning of Representations
SSIM	Structural Similarity Index
SSL	Self-Supervised Learning (өзін-өзі бақылаусыз оқыту)
STARE	Structured Analysis of the Retina (деректер жиынтығы)

UML	Unified Modeling Language
VRAM	Video Random-Access Memory
VVI	Vessel Visibility Index
WSL	Windows Subsystem for Linux
XAI	Explainable Artificial Intelligence
D	Көру өрісінің (FOV) диаметрі, пиксельмен
CL	CLANE түрлендіруінің клип-лимиті
F1	F1-score (precision және recall гармоникалық орташасы)
G	Жалпылау коэффициенті, $G = F1_external / F1_EyePACS$
T	Қос шектеулі CLANE-нің ғаламдық шектік мәні (T/80 формуляциясы)
α	Focal Loss класс салмағы параметрі (кері жиілік)
γ	Focal Loss фокустау параметрі ($\gamma = 2$)
к	Квадраттық салмақтары бар Cohen's Карра
σ	Flat-field correction-дегі Гаусс ядросының стандартты ауытқуы, $\sigma = 0.07 \cdot D$
$\Delta F1$	Деректер жиынтығы аралық F1 төмендеуі, $\Delta F1 = F1_EyePACS - F1_external$

АНЫҚТАМАЛАР

Архитектуралық күрделілік (Architectural complexity) — CNN сыйымдылығы, конволюциялық қабаттар саны, оқытылатын параметрлердің жалпы саны, сүзгі өлшемдерінің ауқымы және регуляризация компоненттерінің (batch normalization, dropout) болуы немесе болмауы арқылы анықталады.

Baseline (базалық тармақ) — Эксперимент 1-дің анықтамалық конфигурациясы: 512×512-ге дейін созып-масштабтау, одан кейін ImageNet нормализациясы; FOV маскасы мен preprocessing кезеңдерінсіз 3 арналы тензор шығарады, магистраль ImageNet-тен инициализацияланады.

CLANE (Contrast-Limited Adaptive Histogram Equalization) — контрастты күшейтуді шектейтін шектік мәнмен жергілікті кескін плиткалары бойынша жұмыс істейтін адаптивті контрастты күшейту әдісі; конвейерде LAB L-арнасына қос шектеулі шектік мәнмен қолданылады (5-кезең).

Композиттік тәуелсіз айнымалы (Composite independent variable) — Эксперимент 1-дің (H-1) біріктірілген басқарылатын факторы, мұнда толық конвейер тармағы baseline-нан preprocessing өсі (сегіз кезеңді конвейер vs. созып-масштабтау + ImageNet) және pretraining өсі (офтальмологияға бейімделген SSL vs. ImageNet) бойынша бірге ерекшеленеді.

Convolutional Neural Network (CNN) — белгілерді шығаруға арналған конволюциялық және pooling қабаттарынан және жіктеуге арналған толық байланысқан қабаттардан тұратын нейрондық архитектура; алдын ала өңделген fundus кескіндерінде бес класты DR градациясын жасайтын жіктеу магистралі.

Cross-Validation — 5 еселі, пациент деңгейінде стратификацияланған бөлуді пайдаланатын валидация стратегиясы; әр итерацияда төрт фолд оқыту, бір фолд тест ретінде қолданылады, бір пациенттің кескіндері екі бөлімде де болмайды; метрикалар орташа $\pm$ стандартты ауытқу түрінде беріледі.

Data Augmentation — оқыту деректерінің варибельділігін арттыру және жалпылауды жақсарту үшін қолданылатын кескін түрлендірулері (аударып шығару, бұру, масштабтау, жарықтық/контраст, PCA түс); конвейердің тек оқытуға арналған 6-кезеңі.

Деректер жиынтығына тән нормализация (Dataset-specific normalization) — ImageNet статистикасының орнына негізгі деректер жиынтығының оқыту бөлігінен есептелген орташа мән мен стандартты ауытқуды пайдаланатын арна бойынша нормализация (7-кезең); толық конвейердің нормализациясы.

Диабеттік ретинопатия (Diabetic Retinopathy, DR) — қант диабетінің микротамырлық асқынуы және алдын алуға болатын көру қабілетінен айырылудың жетекші себебі; бес ауырлық сатысында градацияланады (0 — жоқ, 1 — жеңіл, 2 — орташа, 3 — ауыр, 4 — пролиферативті).

Диагностикалық тиімділік (Diagnostic effectiveness) — тест бөлімінде есептелген төрт негізгі метрика (accuracy, weighted F1-score, ROC-AUC және квадраттық салмақты Cohen's Kappa) бойынша бірлескен өнімділік профилі.

Domain Shift — бейнелеу жабдығының, пациенттер популяциясының немесе алу хаттамаларының айырмашылықтарынан туындайтын оқыту деректері мен мақсатты деректер арасындағы таралымдық айырмашылық.

FOV маскасы (Field-of-View mask) — 3-кезеңде жасалатын және 4-арна ретінде қосылатын бинарлық кеңістіктік маска (1.0 = нақты fundus деректері, 0.0 = нөлдік толтыру), CNN-ге нақты ретинальды пиксельдерді толтырылған фоннан ажыратуға мүмкіндік береді.

Flat-Field Correction (адаптивті) — FOV маскасы ішінде біркелкі емес жарықтандыруды қалыпқа келтіретін, жергілікті контрастты сақтайтын адаптивті $\sigma = 0.07 \cdot D$ ($D = \text{FOV}$ диаметрі) бар Гаусс бұлыңғырлауын азайту; конвейердің 4-кезеңі.

Fundus кескіні (Fundus image) — фундоскопия арқылы алынған ретинальды фотосурет; диссертацияның жалғыз бейнелеу модальділігі және preprocessing конвейері мен CNN жіктеуішінің кірісі.

Жалпылау (cross-database) — сол бір оқытылған модельмен қайта оқытусыз екінші деректер жиынтығындағы тест F1-score-дың негізгі деректер жиынтығындағы тест F1-score-ға қатынасы; жалпылау коэффициенті $G = F1_{\text{external}} / F1_{\text{EyePACS}}$.

Grad-CAM (Gradient-weighted Class Activation Mapping) — соңғы конволюциялық белгілер карталарының градиентпен өлшенген комбинациясынан класс-дискриминативті локализация карталарын жасайтын explainability әдісі; патологияны клиникалық локализациялау емес, интерпретация құралы.

Кескін сапасы (Image quality) — fundus кескінінің DR градациясына қатысты микротамырлық белгілерді автоматты түрде анықтауды қолдаудың өлшенетін қабілеті; субъективті визуалды баға арқылы емес, төмен ағындағы жіктеу өнімділігі арқылы бағаланады.

Интеграцияланған конвейер үстемдігі (H-1) — біріктірілген толық конвейер конфигурациясы baseline-нан біртұтас жүйе ретінде асып түседі деген негізгі гипотеза; эмпирикалық үстемдік критерийі ($\text{weighted F1} \geq 5$ пп өсу, $\text{ROC-AUC} \geq 0.02$ өсу, Карра нашарламауы) орындалғанда валидацияланады.

Офтальмологияға бейімделген өзін-өзі бақылаусыз алдын ала оқыту — CNN магистралін белгіленбеген ретинальды fundus корпусында (DR белгілерінсіз) өзін-өзі бақылаусыз алдын ала оқыту; толық конвейер тармағының инициализациясы ретінде қолданылады, 4-арналы конвейер тензорында fundus-домен репрезентацияларын үйренеді.

Physician-in-the-Loop — дәрігер AI шығысын тек тұтынушы ретінде емес, нәтижелерді интерпретациялайтын және жүйені баптайтын «баптаушы» әрі аудитор ретінде әрекет ететін жобалау парадигмасы; ұсынылған жүйе осы парадигма аясындағы шешім қабылдауды қолдау құралы.

Preprocessing Pipeline (алдын ала өңдеу конвейері) — CNN кірісіне дейін fundus кескіндеріне қолданылатын канондық сегіз кезеңді реттелген тізбек (0–7 кезеңдер); толық конвейер барлық сегіз кезеңді қолданып, 4-арналы тензор (RGB + FOV маскасы) шығарады.

Ресурстары шектеулі орта (Resource-limited environment) — келесілердің кемінде екеуімен сипатталатын орналастыру контексті: GPU үдетуінің болмауы; қолжетімді RAM 16 ГБ-тан төмен; пакеттік өңдеу уақытының шектеулері; үздіксіз бұлттық API-ге сенуге мүмкіндік бермейтін желілік байланыс.

Transfer Learning — алдын ала оқытылған желі салмақтарын fundus-кескін доменіне қайта пайдалану және бейімдеу; H-1 бойынша инициализация көзі тармаққа бағынады (baseline үшін ImageNet, толық конвейер үшін офтальмологияға бейімделген SSL).

Weighted Loss Function — класс теңсіздігін шешетін және бес класты DR градациясының реттік құрылымын пайдаланатын класс бойынша салмақтары бар кросс-энтропия шығын функциясы.